

BA2 – Estadística para la Toma de Decisiones

Clase 2 · Hora 1: Población, muestra, muestreo y sesgos

Alexander Buriticá Casanova

Business Analytics · 2026-1

Febrero 2026

Estructura de la clase

- ① **(Teoría):** población, muestra, parámetros, estadísticos, muestreo, sesgos y validez.
- ② **(Guía en R):** simulación + muestreo + estadísticos (paso a paso).
- ③ **(Taller fácil, evaluable):** aplicar el flujo con otro escenario y responder preguntas cortas.

Idea central: la credibilidad del análisis depende de *cómo* obtenemos la muestra y *qué* calculamos con ella.

¿Por qué necesitamos estadística hoy?

- Vivimos en un contexto de **abundancia extrema de datos**.
- Tener datos no garantiza buenas decisiones.
- El reto es **resumir, entender e interpretar** información compleja.

La estadística transforma datos en **evidencia para decidir**.

Conceptos base: población, muestra y variable de interés

Población

Conjunto total de unidades sobre las que queremos decidir (clientes, empresas, transacciones, teléfonos, etc.).

Variable de interés

Característica que medimos en cada unidad (ventas, salario, duración de batería, gasto, etc.).

Muestra

Subconjunto observado de la población. Idealmente, seleccionado de forma que represente bien a la población.

¿Por qué muestreamos?

- Costos y tiempo
- Acceso limitado a la población
- Necesidad de decidir con información parcial

Idea central

La inferencia estadística solo tiene sentido si el muestreo es razonable.

Parámetros vs. estadísticos (idea clave)

Parámetro (población)


- Describe a la **población**.
- Es **desconocido** en la práctica.
- Ejemplos: media μ , varianza σ^2 , proporción p .

Estadístico (muestra)

- Se calcula con la **muestra**.
- Es **observable**.
- Ejemplos: media $\bar{X}$, varianza S^2 , proporción $\hat{p}$.

Traducción BA: usamos estadísticos como **evidencia** para aproximar parámetros y tomar decisiones.

El flujo de la estadística (visión completa)



Cómo leer el flujo (paso a paso)

- ❶ **Población:** existe una variable de interés X .
- ❷ **Muestreo:** obtenemos una muestra $(X_1, \dots, X_n)$.
- ❸ **Parámetros:** describen la población, pero son desconocidos.
- ❹ **Estadísticos:** se calculan con la muestra y sí son observables.
- ❺ **Estimación:** usamos estadísticos para aproximar parámetros.

Ejemplo rápido: duración de batería

Escenario: estimar la **duración promedio** de la batería de un modelo de teléfono.

- Población: todos los teléfonos del modelo.
- Variable de interés: horas de batería (X).
- Parámetro: μ (desconocido).
- Muestra: $n = 30$ teléfonos seleccionados aleatoriamente.
- Estadístico: $\bar{X}$ como estimación de μ .

Mensaje BA: el número calculado depende de la muestra; más adelante cuantificaremos esa incertidumbre.

¿Qué significa “muestra aleatoria”?

- Un procedimiento donde cada unidad tiene oportunidad conocida (o al menos no sesgada) de ser seleccionada.
- Buscamos que la muestra sea **representativa**.
- Si el muestreo falla, el análisis puede ser preciso... pero **equivocado**.

Advertencia

Aumentar el tamaño muestral no corrige un sesgo sistemático de selección.

Muestreo, sesgos y validez

¿Por qué cómo recolectamos los datos importa tanto como el análisis?

Motivación: el problema no es R

“Un análisis perfecto con una mala muestra lleva a malas decisiones.”

Ejemplos comunes:

- Encuesta de satisfacción solo a clientes activos
- A/B test hecho solo en usuarios premium
- Estudio de mercado con respuestas voluntarias

Conclusión: el problema no es el modelo, es la **muestra**.

Población vs. muestra (en decisiones de negocio)

- **Población:** sobre quién quiero decidir.
- **Muestra:** a quién estoy observando.

Pregunta clave: *¿esta muestra representa bien a la población de interés?*

Muestreo probabilístico

Un muestreo es **probabilístico** si:

- Cada unidad tiene una probabilidad conocida y mayor que cero de ser seleccionada.

Idea formal (sin entrar en detalles):

$$P(\text{unidad } i \text{ es seleccionada}) = \pi_i > 0$$

Consecuencia clave:

- Podemos cuantificar la incertidumbre (intervalos de confianza, pruebas).
- Los resultados tienen interpretación estadística clara.

Tipos de muestreo probabilístico

- **Aleatorio simple:** todos tienen la misma probabilidad.
- **Sistemático:** se selecciona cada k -ésima unidad.
- **Estratificado:** se divide la población en grupos homogéneos.
- **Por conglomerados:** se seleccionan grupos completos.

Todos cumplen la condición clave: probabilidades conocidas.

Ejemplos rápidos de muestreo probabilístico

- **Aleatorio simple:** De 10.000 clientes, seleccionar 500 usando un generador aleatorio.
- **Sistemático:** Ordenar clientes y seleccionar cada 20º después de un inicio aleatorio.
- **Estratificado:** Muestrear clientes por región manteniendo proporciones.
- **Conglomerados:** Seleccionar 10 sucursales y encuestar a todos los clientes de cada una.

Muestreo no probabilístico

Aquí empieza el riesgo

Un muestreo es **no probabilístico** cuando:

- No se conoce la probabilidad de selección.
- La selección depende de conveniencia, acceso o decisión humana.

Consecuencia:

- No podemos medir formalmente la incertidumbre.
- La inferencia estadística es limitada o inválida.

Sesgo: la palabra peligrosa

Sesgo = error sistemático

No se corrige aumentando el tamaño de la muestra.

Ejemplos típicos:

- Solo clientes satisfechos responden encuestas.
- Bases de datos que incluyen solo usuarios activos.
- Encuestas realizadas solo en horario laboral.

Clave BA: Un estimador sesgado puede ser muy preciso... y muy equivocado.

Validez externa

Pregunta clave:

¿Puedo extrapolar estos resultados a otros contextos, personas o momentos?

- Alta validez externa $\neq$ muestra perfecta.
- Baja validez externa $\neq$ análisis inútil.

Todo depende de:

- La población objetivo real.
- El tipo de decisión que se quiere tomar.
- El costo de equivocarse.

Dos grandes ramas de la estadística

Estadística descriptiva

- Resume y organiza datos observados.
- Tablas, gráficos, promedios, percentiles, dispersión.
- Responde: *¿Qué dicen los datos que tengo?*

Estadística inferencial

- Usa una muestra para aprender sobre la población.
- Intervalos de confianza, pruebas, modelos.
- Responde: *¿Qué puedo concluir sobre la población?*

¿Qué es una estadística?

Una **estadística** es una medida numérica calculada a partir de la muestra.

Formalmente:

$$H(X_1, X_2, \dots, X_n)$$

- Se conoce cuando observamos la muestra.
- Cambia de una muestra a otra.
- No depende de parámetros poblacionales desconocidos.

Tipos de variables

Cuantitativas

- Razón (cero absoluto)
- Intervalo (cero arbitrario)

Cualitativas

- Ordinal
- Nominal

Estadísticas descriptivas

Se agrupan en tres categorías:

- Medidas de tendencia central
- Medidas de variabilidad
- Medidas de posición

Medidas de tendencia central

- Media ($\bar{X}$)
- Mediana (Md)
- Moda (Mo)

Indican el **centro** de la distribución de los datos.

Media muestral (ejemplo con datos)

Datos (horas/semana, $n = 12$):

(2, 3, 4, 4, 5, 6, 6, 6, 7, 8, 10, 12)

Media:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{2 + 3 + 4 + 4 + 5 + 6 + 6 + 6 + 7 + 8 + 10 + 12}{12} = \frac{73}{12} = 6,08$$

Interpretación: en promedio, los estudiantes dedican **6.08 horas/semana**.

Mediana (ejemplo con datos)

Datos ordenados:

(2, 3, 4, 4, 5, 6, 6, 6, 7, 8, 10, 12)

Como $n = 12$ (par), la mediana es el promedio del 6º y 7º dato:

$$Md = \frac{x_{(6)} + x_{(7)}}{2} = \frac{6 + 6}{2} = 6$$

Interpretación: el **50 %** de los estudiantes dedica **6 horas o menos**.

Moda (ejemplo con datos)

Frecuencias rápidas:

- 4 aparece 2 veces
- 6 aparece 3 veces
- los demás aparecen 1 vez

$$Mo = 6$$

Interpretación: el valor más frecuente en la muestra es **6 horas/semana**.

Media vs mediana ante valores extremos

Muestra original: $\bar{X} = 6,08$, $Md = 6$

Supón un valor extremo: el último dato pasa de 12 a 30

(2, 3, 4, 4, 5, 6, 6, 6, 7, 8, 10, 30)

Nueva media:

$$\bar{X}' = \frac{73 - 12 + 30}{12} = \frac{91}{12} = 7,58$$

La mediana sigue siendo:

$$Md' = 6$$

Mensaje BA: la media es sensible a outliers; la mediana no.

Variabilidad (ejemplo con datos)

Con el mismo dataset:

(2, 3, 4, 4, 5, 6, 6, 6, 7, 8, 10, 12)

$$\bar{X} = 6,08$$

Objetivo: medir qué tan dispersos están los datos alrededor de $\bar{X}$.

- Varianza (S^2)
- Desviación estándar (S)
- Coeficiente de variación (CV)

Varianza y desviación estándar (ejemplo)

Media: $\bar{X} = 6,08$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Para estos datos:

$$S^2 \approx 7,54 \quad \Rightarrow \quad S = \sqrt{S^2} \approx 2,75$$

Interpretación: típicamente, las horas se desvían **2.75 horas** alrededor del promedio.

Varianza y desviación estándar (intuición)

Media muestral: $\bar{X} = 6,08$ horas

Idea clave:

- La **varianza** mide cuánto se alejan los datos del promedio
- La **desviación estándar** expresa esa dispersión en las mismas unidades de la variable

Resultados para la muestra:

$$S^2 \approx 7,54 \quad (\text{horas}^2)$$

$$S \approx 2,75 \quad \text{horas}$$

Interpretación:

- La varianza es un paso intermedio (no se interpreta directamente)
- La desviación estándar indica que los datos se alejan típicamente unas **2.75 horas** del promedio

Coeficiente de variación

$$CV = \frac{S}{\bar{X}}$$

Para la muestra (general):

$$CV = \frac{2,75}{6,08} = 0,45 \quad (\approx 45 \%)$$

Comparación entre deportes (ejemplo):

- **Fútbol:** $\bar{X} = 7,0$, $S = 2,0 \Rightarrow CV = 0,29$
- **Yoga:** $\bar{X} = 3,5$, $S = 2,0 \Rightarrow CV = 0,57$

Interpretación: aunque la desviación es igual, **Yoga es más variable en términos relativos.**

Percentiles (ejemplo con datos)

Datos ordenados (n=12):

(2, 3, 4, 4, 5, 6, 6, 6, 7, 8, 10, 12)

Percentil 50 (P50): es la mediana

$$P_{50} = 6$$

Percentil 90 (P90): Posición aproximada: $0,9 \times n = 10,8 \Rightarrow$ miramos entre el 11º y 12º dato.

$$x_{(11)} = 10, \quad x_{(12)} = 12 \Rightarrow P_{90} \approx 10 \text{ a } 12$$

Interpretación: el 90 % dedica **aprox. 10–12 horas o menos**.

Percentiles

Con nuestros datos:

- $P_{50} = 6$: la mitad dedica **6 horas o menos**.
- $P_{90} \approx 10-12$: solo el 10 % dedica más que eso.

Uso típico en negocios

Percentiles sirven para fijar metas y segmentar:

- “Top 10 %” de usuarios por consumo
- SLA: “90 % de entregas en menos de X días”

Puente a la hora 2 (R guiado)

En la siguiente hora vamos a construir este flujo con un ejemplo:

- ➊ Calcular estadísticos (media, varianza, proporción).
- ➋ Simular una población (para “ver” lo que normalmente es inobservable).
- ➌ Tomar múltiples muestras aleatorias.